

A8-Series de tiempo

Eryk Elizondo González A01284899

2024-11-12

```
ventas <- c(4.8, 4.1, 6, 6.5, 5.8, 5.2, 6.8, 7.4, 6, 5.6, 7.5, 7.8, 6.3, 5.9, 8, 8.4)
serie <- ts(ventas, start = c(1,1), frequency = 4)
```

1. Realiza el análisis de tendencia y estacionalidad:

1. Identifica si es una serie estacionaria

H0: La serie no es estacionaria H1: La serie es estacionaria


```
adf_test <- adf.test(serie)
print(adf_test)

##
## Augmented Dickey-Fuller Test
##
## data:  serie
## Dickey-Fuller = -2.7111, Lag order = 2, p-value = 0.3015
## alternative hypothesis: stationary
```

Según la prueba de Dickey-Fuller, no hay evidencia estadísticamente significativa para rechazar la hipótesis nula, lo que significa que la serie no es estacionaria.

2. Grafica la serie para verificar su tendencia y estacionalidad

```
plot(serie, main = "Datos de Ventas Trimestrales", ylab = "Ventas", xlab = "Tiempo (Trimestres)", col = "blue", type = "o")
```




Visualmente se observa una tendencia positiva que no refleja el comportamiento de una serie estacionaria.

3. Analiza su gráfico de autocorrelación

```
acf(serie, main = "Autocorrelación de Ventas")
```

Autocorrelación de Ventas



```
qnorm(1-0.05/2)/sqrt(length(serie))
```


```
## [1] 0.489991
```

Hay 2 autocorrelaciones significativas, estas siendo lag = 0 y 1.

4. Identifica si el modelo puede ser sumativo o multiplicativo (puedes probar con ambos para ver con cuál es mejor el modelo)


```
decomp_a <- decompose(serie, type = "additive")  
plot(decomp_a)
```

Decomposition of additive time series



```
decomp_m <- decompose(serie, type = "multiplicative")  
plot(decomp_m)
```

Decomposition of multiplicative time series




Es mejor usar una descomposición multiplicativa ya que la sumativa no entrega un modelo significativo.

2. Calcula los índices estacionales y grafica la serie desestacionalizada

```
seasonal_indices <- decomp_m$seasonal
seasonal_indices

##           Qtr1           Qtr2           Qtr3           Qtr4
## 1 0.9306617 0.8363763 1.0915441 1.1414179
## 2 0.9306617 0.8363763 1.0915441 1.1414179
## 3 0.9306617 0.8363763 1.0915441 1.1414179
## 4 0.9306617 0.8363763 1.0915441 1.1414179

deseasonalized_sales <- ventas / seasonal_indices
deseasonalized_series <- ts(deseasonalized_sales, start = c(1,1), frequency = 4)
plot(deseasonalized_series, main = "Serie Desestacionalizada", ylab = "Ventas (desestacionalizadas)", xlab = "Tiempo")
```



3. Analiza el modelo lineal de la tendencia

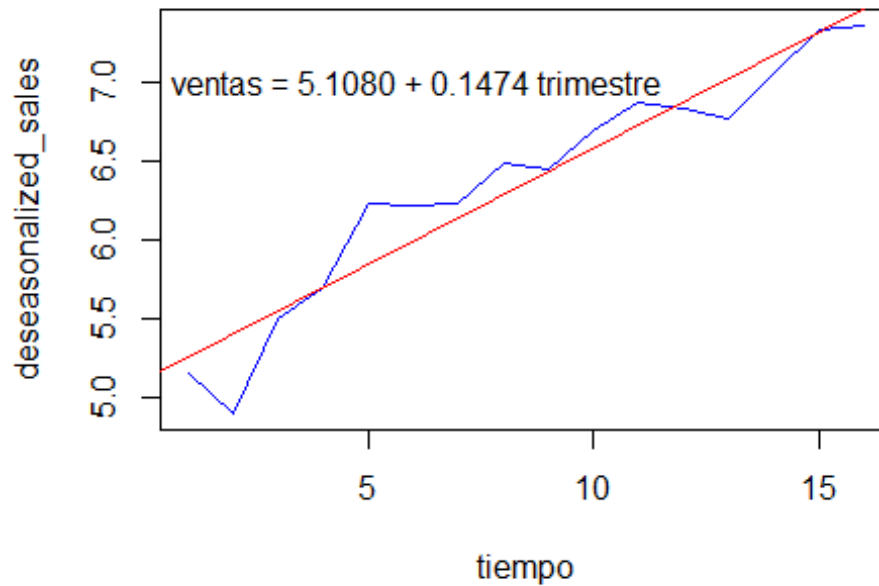
1. Realiza la regresión lineal de la tendencia (ventas desestacionalizadas vs tiempo)

```
tiempo <- 1:16
N <- lm(deseasonalized_sales ~ tiempo)
summary(N)

##
## Call:
## lm(formula = deseasonalized_sales ~ tiempo)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.5007 -0.1001  0.0037  0.1207  0.3872
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.10804    0.11171   45.73  < 2e-16 ***
## tiempo      0.14738    0.01155   12.76 4.25e-09 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.213 on 14 degrees of freedom
## Multiple R-squared:  0.9208, Adjusted R-squared:  0.9151
## F-statistic: 162.7 on 1 and 14 DF, p-value: 4.248e-09

plot(tiempo, deseasonalized_sales, main = "Tendencia Lineal de Ventas
Desestacionalizadas", type = "l", col = "blue")
abline(N, col = "red")
text(6, 7, "ventas = 5.1080 + 0.1474 trimestre")
```

Tendencia Lineal de Ventas Desestacionalizadas




2. Analiza la significancia del modelo lineal, global e individual

El modelo es significativo con un valor p de 4.248e-09, ambos coeficientes son significativos teniendo valores p debajo del umbral 0.05.

3. Haz el análisis de residuos

```
residuals <- residuals(N)
plot(residuals, main = "Residuos del Modelo Lineal", ylab = "Residuos", xlab = "Tiempo")
abline(h = 0, col = "red")
```



Hay una ligera tendencia de los residuos a los positivos y parecen estar uniformemente dispersos, aunque no parecen ser completamente independientes los residuos, no aparentan una tendencia notoria o significativa de autocorrelación.

4. Calcula el CME y el EPAM de la predicción de la serie de tiempo

```
CME <- mean(residuals^2, na.rm = TRUE)
EPAM <- mean(abs(residuals / deseasonalized_sales)) * 100
print(CME)

## [1] 0.0397064

print(EPAM)

## [1] 2.439533
```

Vemos que la predicción posee un error cuadrático medio bajo este siendo 0.04 y el promedio de errores porcentuales igualmente es bajo.


5. Explora un mejor modelo, por ejemplo un modelo cuadrático: $y = .$ Para ello transforma la variable ventas (recuerda que la regresión no lineal es una regresión lineal con una transformación).

```
tiempo_2 <- tiempo^2
MC <- lm(deseasonalized_sales ~ tiempo + tiempo_2)
summary(MC)

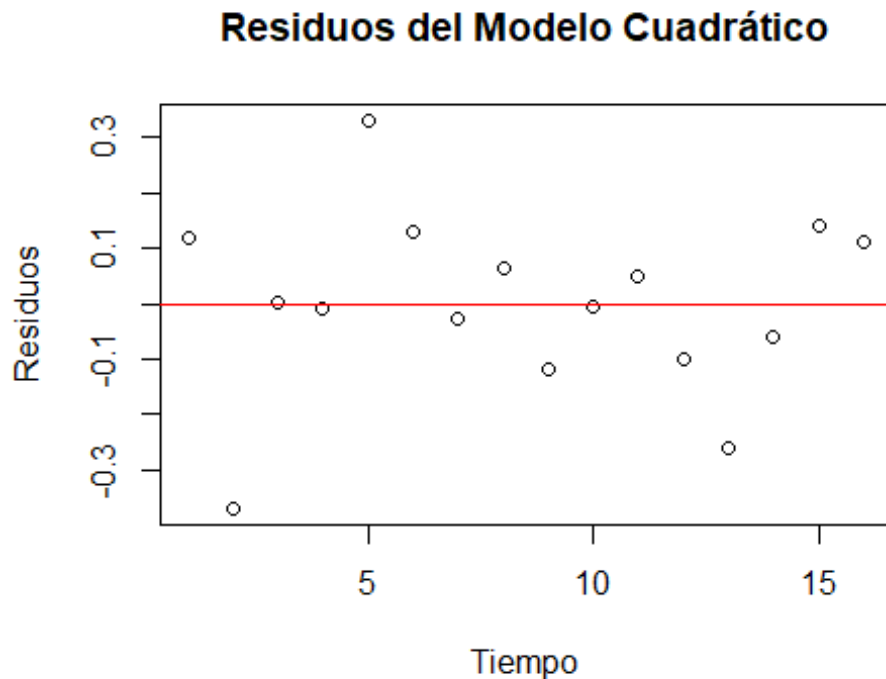
##
## Call:
## lm(formula = deseasonalized_sales ~ tiempo + tiempo_2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.36986 -0.07058 -0.00100  0.11345  0.33110
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  4.790283   0.152429  31.426 1.20e-13 ***
## tiempo       0.253302   0.041269   6.138 3.56e-05 ***
## tiempo_2     -0.006231   0.002360  -2.640  0.0204  *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1784 on 13 degrees of freedom
## Multiple R-squared:  0.9484, Adjusted R-squared:  0.9405
## F-statistic: 119.6 on 2 and 13 DF, p-value: 4.268e-09

plot(tiempo, deseasonalized_sales, main = "Tendencia Cuadrática de Ventas
Desestacionalizadas",
     type = "l", col = "blue", xlab = "Tiempo", ylab = "Ventas
Desestacionalizadas")
lines(tiempo, predict(MC), col = "red", lwd = 2)
```

Tendencia Cuadrática de Ventas Desestacionalizadas



```
residuals_MC <- residuals(MC)
plot(residuals_MC, main = "Residuos del Modelo Cuadrático", ylab =
"Residuos", xlab = "Tiempo")
abline(h = 0, col = "red")
```



6. Concluye sobre el mejor modelo


El modelo cuadrático parece ser igualmente significativo que el lineal pero con errores mucho más independientes, dispersos y aleatorios que representan mejor la información.

7. Realiza el pronóstico para el siguiente año y gráficalo junto con los pronósticos previos y los datos originales.

```
tiempo_futuro <- 1:20
predicted_deseasonalized <- predict(MC, newdata = data.frame(tiempo =
tiempo_futuro, tiempo_2 = tiempo_futuro^2))
prediccion <- predicted_deseasonalized * seasonal_indices[1:4]

plot(tiempo, serie, xlim = c(1, 20), ylim = c(min(serie), max(c(serie,
prediccion))),
     main = "Pronóstico de Ventas para el Próximo Año",
     ylab = "Ventas", xlab = "Tiempo (Trimestres)", col = "blue", type = "o")
lines(tiempo, deseasonalized_series, col = "green", type = "o", lty = 2)
lines(tiempo_futuro, prediccion, col = "red", type = "o", pch = 19)
legend("topleft", legend = c("Ventas Originales", "Ventas
Desestacionalizadas", "Pronóstico"),
```

```
col = c("blue", "green", "red"), lty = c(1, 2, 1), pch = c(NA, NA, 19))
```



Observamos que el pronóstico derivado del modelo cuadrático sigue la tendencia de las ventas y las extrapola consistentemente, con esto podemos concluir que el modelo cuadrático es apto para pronosticar las ventas de estos datos.